

Macierze

Wszystkie zadania rozwiązujemy bez używania pętli.

Zadanie 5.1 (MG).

Niech \mathbf{t} będzie wektorem o n elementach będących liczbami całkowitymi ze zbioru $\{1, \dots, k\}$. Napisz funkcję, która dokona kodowania elementów t_i (*one-hot-encode*). Funkcja powinna zwracać macierz zero-jedynkową R wymiaru $n \times k$ taką, że $r_{i,j} = 1$ wtedy i tylko wtedy gdy $t_i = j$. Taka reprezentacja jest przydatna np. w problemie klasyfikacji wieloetykietowej przy użyciu k klasyfikatorów.

Let \mathbf{t} be vector of n integers in $\{1, \dots, k\}$. Write a function to one-hot-encode each t_i . Return a 0-1 matrix R of size $n \times k$ such that $r_{i,j} = 1$ if and only if $t_i = j$. By the way, such a representation is useful when solving, e.g., a multiclass classification problem by means of k binary classifiers.

Zadanie 5.2 (MG).

Dokonaj przekształcenia *softmax* każdego wiersza macierzy $\mathbf{X} \in \mathbb{R}^{n \times k}$, tzn. przekształcenia postaci:

$$x_{i,j} \mapsto \frac{\exp(x_{i,j})}{\sum_{l=1}^k \exp(x_{i,l})}.$$

Następnie dokonaj odkodowania każdego wiersza (*one-hot decode*), tj. dla każdego wiersza należy znaleźć numer kolumny o wartości najbardziej zbliżonej do 1. Zwróć wektor n -elementowy.

Given an $n \times k$ matrix with elements in \mathbb{R} , apply the softmax function to each row, i.e., $x_{i,j} \mapsto \frac{\exp(x_{i,j})}{\sum_{l=1}^k \exp(x_{i,l})}$. Then one-hot decode the values in each row, i.e., find the column number with the value most close to 1. Return a vector of size n .

Zadanie 5.3 (MG).

Niech dana będzie macierz $\mathbf{X} \in \mathbb{R}^{n \times d}$. Wyznacz przedział wielowymiarowy ograniczający wartości n punktów reprezentowanych jako \mathbf{X} . Dokładniej, wyznacz i zwróć macierz $\mathbf{B} \in \mathbb{R}^{2 \times d}$ taką, że $b_{1,j} = \min_i x_{i,j}$ oraz $b_{2,j} = \max_i x_{i,j}$.

For a given $\mathbf{X} \in \mathbb{R}^{n \times d}$, determine the bounding hyperrectangle of the n points. Return a matrix $\mathbf{B} \in \mathbb{R}^{2 \times d}$ with $b_{1,j} = \min_i x_{i,j}$ and $b_{2,j} = \max_i x_{i,j}$.

Zadanie 5.4 (MG).

Niech macierz \mathbf{X} wymiaru $n \times d$ reprezentuje n punktów w \mathbb{R}^d . Napisz funkcję, która wyznaczy i zwróci odległości między punktami z \mathbf{X} oraz (danym jako drugi argument funkcji) punktem $\mathbf{y} \in \mathbb{R}^d$. Funkcja powinna zwrócić wektor $\mathbf{d} \in \mathbb{R}^n$ taki, że $d_i = \|\mathbf{x}_{i,\cdot} - \mathbf{y}\|_2$.

Assume that an $n \times d$ matrix \mathbf{X} represents n points in \mathbb{R}^d . Write a function that determines the pairwise distances between all the points in \mathbf{X} and a given $\mathbf{y} \in \mathbb{R}^d$. Return a vector $\mathbf{d} \in \mathbb{R}^n$ with $d_i = \|\mathbf{x}_{i,\cdot} - \mathbf{y}\|_2$.

Zadanie 5.5 (MG; Dyskretna dwuwymiarowa zmienna losowa).

Dana jest macierz $P \geq 0$ rozmiaru $n \times m$ taka, że $\sum_{i=1}^n \sum_{j=1}^m p_{i,j} = 1$ oraz posortowane rosnąco wektory liczbowe \mathbf{x} (n -elementowy) i \mathbf{y} (m -elementowy). Trójka $(\mathbf{x}, \mathbf{y}, P)$ opisuje rozkład prawdopodobieństwa pewnej dwuwymiarowej zmiennej losowej dyskretnej (X, Y) , tak jak w poniższym podzadaniu.

W pewnej szkole rozkład prawdopodobieństwa uzyskania ocen z Filozofii Bytu i Wychowania Fizycznego przez tego samego studenta przedstawia się następująco.

		WF			
		2	3	4	5
FB	2	0	0,01	0,1	0,2
	3	0,01	0,05	0,03	0,1
	4	0,1	0,03	0,05	0,01
	5	0,2	0,1	0,01	0

a) Zmienne losowe X i Y są niezależne wtedy i tylko wtedy, gdy dla każdego i, j zachodzi $p_{i,j} = (\sum_{k=1}^n p_{k,j})(\sum_{l=1}^m p_{i,l})$. Napisz funkcję **niezalezosc()**, która sprawdza, czy zachodzi ta własność dla danych $(\mathbf{x}, \mathbf{y}, P)$ (zwracamy wartość logiczną).

b) Ponadto napisz funkcję **podststat()**, która dla $(\mathbf{x}, \mathbf{y}, P)$ zwróci wektor liczbowy (z ustalonym atrybutem **names** – dowolne, lecz czytelne dla użytkownika etykiety) zawierający wartości podstawowych charakterystyk (X, Y) :

- Wartości oczekiwane: $\mathbb{E} X = \sum_{i=1}^n x_i \sum_{j=1}^m p_{i,j}$, $\mathbb{E} Y = \sum_{j=1}^m y_j \sum_{i=1}^n p_{i,j}$,
- Wariancje: $\text{Var } X = \mathbb{E} X^2 - (\mathbb{E} X)^2$, gdzie $\mathbb{E} X^2 = \sum_{i=1}^n x_i^2 \sum_{j=1}^m p_{i,j}$ oraz $\text{Var } Y = \mathbb{E} Y^2 - (\mathbb{E} Y)^2$, gdzie $\mathbb{E} Y^2 = \sum_{j=1}^m y_j^2 \sum_{i=1}^n p_{i,j}$,
- Kowariancję: $\text{Cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E} X \mathbb{E} Y$ dla $\mathbb{E}(XY) = \sum_{i=1}^n \sum_{j=1}^m x_i y_j p_{i,j}$,
- Współczynnik korelacji: $\varrho(X, Y) = \text{Cov}(X, Y) / \sqrt{\text{Var } X \text{Var } Y}$.

Zadanie 5.6 (MG; Średnia ruchoma).

Napisz funkcję **movingavg()**, która dla danego szeregu czasowego \mathbf{x} o n elementach oraz nieparzystej liczby naturalnej k wyznaczy k -średnią ruchomą, $k < n$, tj. szereg czasowy (w_1, \dots, w_{n-k+1}) , dla którego $w_i = \sum_{j=1}^k x_{i+j-1} / k$. Jednostki czasu dla wynikowego szeregu dobierz wedle uznania.

Wbudowany szereg czasowy **UKgas** zawiera dane na temat kwartalnej konsumpcji gazu w Zjednoczonym Królestwie. Użyj go do przetestowania zaimplementowanego algorytmu. Szereg możesz narysować, wywołując **plot(UKgas)**.